

Laporan Praktikum Minggu Ke-5 Kontrol Cerdas

Minggu ke-5

Nama : Bara Hafidz Adz Dzikro

NIM : 224308053

Kelas : TKA 7C

Akun Github (Tautan): <https://github.com/barahafidz224308053tka-maker>

1. Judul Percobaan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Tujuan dari percobaan ini, sebagai berikut:

- Memahami konsep Deep Reinforcement Learning (DRL) dalam kontrol sistem kompleks.
- Mengimplementasikan Deep Q-Network (DQN) untuk kontrol otomatis.
- Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

Deep Reinforcement Learning (DRL) adalah cabang dari kecerdasan buatan yang menggabungkan dua pendekatan utama yaitu Reinforcement Learning (RL) dan Deep Learning (DL). RL berfokus pada bagaimana sebuah agen (agent) belajar membuat keputusan dengan cara berinteraksi dengan lingkungan untuk memaksimalkan total hadiah (reward) yang diperolehnya dari waktu ke waktu. Sementara itu, DL digunakan untuk mengaproksimasi fungsi-fungsi kompleks dalam RL seperti policy (strategi pengambilan keputusan) atau value function (fungsi nilai) menggunakan jaringan saraf dalam (deep neural networks). Kombinasi keduanya memungkinkan DRL menangani masalah dengan ruang

keadaan (state space) yang sangat besar dan kompleks, seperti gambar atau data sensorik yang mentah, yang sebelumnya sulit dipecahkan dengan metode RL tradisional (Dong et al., 2022). Dalam RL tradisional, terdapat beberapa algoritma utama yang digunakan, yaitu Dynamic Programming (DP), Monte Carlo (MC) methods, dan Temporal-Difference (TD) learning. Dynamic Programming digunakan ketika model lingkungan diketahui sepenuhnya, sehingga agen dapat menghitung nilai optimal secara langsung menggunakan persamaan Bellman. Namun, karena kondisi tersebut jarang terpenuhi di dunia nyata, muncullah pendekatan Monte Carlo dan TD yang lebih praktis. Monte Carlo methods memperkirakan nilai rata-rata reward dengan menjalankan banyak episode pengalaman lengkap, sementara TD learning seperti SARSA dan Q-Learning memperbarui nilai secara bertahap setelah setiap langkah interaksi tanpa menunggu episode selesai (Yamagata et al., 2023). Penggunaan Deep Q-Network (DQN) dapat digunakan dalam berbagai aplikasi kompleks termasuk Human Pose Estimation (HPE).

Human Pose Estimation (HPE) merupakan teknologi dalam bidang computer vision yang bertujuan untuk mendeteksi dan menganalisis posisi serta orientasi sendi tubuh manusia dari gambar atau video (Samkari et al., 2023). Menurut penelitian yang dilakukan (Achmad Ivan Taruna Jaya et al., 2024) Human Pose Estimation (HPE) telah mengalami perkembangan signifikan dari metode tradisional berbasis visi komputer menuju pendekatan berbasis deep learning yang lebih akurat dan efisien. Framework seperti DeepPose, Convolutional Pose Machines, dan HRNet telah memperkenalkan arsitektur jaringan saraf konvolusional yang mampu memprediksi koordinat tubuh secara langsung dan mempertahankan representasi resolusi tinggi selama proses inferensi.

Deep Q-Network (DQN) merupakan metode yang berasal dari Deep Reinforcement Learning (DRL) dan dirancang untuk belajar mengendalikan sistem secara otomatis melalui interaksi langsung dengan lingkungan, tanpa perlu model matematis yang sudah diketahui. DQN menggunakan jaringan saraf dalam (deep neural network) untuk memperkirakan nilai dari setiap aksi (Q-function),

sehingga agen dapat memilih tindakan terbaik untuk mencapai hasil optimal. Pendekatan ini sangat efektif dalam menangani sistem yang kompleks, nonlinier, dan tidak pasti (stokastik). Sementara itu, metode kontrol klasik seperti PID (Proportional–Integral–Derivative) dan Fuzzy Logic Control (FLC) bekerja berdasarkan aturan yang telah ditentukan secara manual oleh manusia. PID mengontrol keluaran sistem dengan menyesuaikan tiga komponen utama — proporsional, integral, dan derivatif — guna memperbaiki perbedaan antara nilai aktual dan nilai target. Metode Fuzzy Logic, di sisi lain, menggunakan logika berbasis aturan “jika–maka” untuk menangani ketidakpastian secara kualitatif (Khater et al., 2025). Dalam berbagai penelitian, salah satunya penelitian yang dilakukan (Qin et al., 2024) DQN terbukti lebih adaptif dan mampu beradaptasi dengan perubahan kondisi lingkungan dibandingkan PID atau Fuzzy Logic, terutama dalam aplikasi yang dinamis seperti kendali robotik dan sistem otonom. Namun, meskipun DQN menawarkan fleksibilitas tinggi, metode klasik tetap unggul dalam hal stabilitas, kemudahan implementasi, dan keandalan waktu nyata pada sistem yang lebih sederhana.

4. Diskusi

- a. Apa kelebihan dan kelemahan DQN dibandingkan metode Q-Learning klasik?

DQN menawarkan beberapa keunggulan signifikan dibandingkan Q-learning tradisional, terutama dalam menangani masalah yang lebih kompleks, berikut beberapa kekurangan dan kelebihan dibandingkan dengan Q-Learning klasik:

- Kekurangan
 - 1) Waktu pelatihan tergolong lambat
 - 2) Memiliki Kompleksitas yang lebih tinggi dibandingkan dengan Q-Learning
 - 3) Butuh data dan pelatihan lebih banyak.
- Keunggulan

- 1) memungkinkan DQN untuk menangani masalah dengan ruang state yang sangat besar, bahkan kontinu.
 - 2) DQN dapat melakukan generalisasi, yaitu menerapkan pengetahuan yang dipelajari dari satu state ke state lain yang serupa.
 - 3) Cocok untuk kontrol sistem dinamis yang kompleks
- b. Bagaimana cara mengadaptasi DQN untuk kontrol sistem dinamis seperti drone atau robot industri?

Deep Q-Network (DQN) adalah terobosan dalam reinforcement learning, menggabungkan deep learning untuk mengatasi keterbatasan Q-learning, sehingga mampu menangani ruang status yang besar dan kompleks, dan juga DQN dapat melakukan generalisasi antar status yang mirip, menjadikannya lebih cocok untuk sistem dinamis seperti drone atau robot industri. Untuk mengimplementasikan DQN untuk kontrol sistem dinamis, terdapat beberapa langkah yang dilakukan, langkah pertama adalah mendefinisikan status dan aksi secara tepat, langkah selanjutnya adalah melakukan pelatihan karena DQN rentan terhadap ketidakstabilan pelatihan, teknik seperti Double DQN, Dueling DQN, dan Experience Replay perlu diterapkan untuk meningkatkan akurasi dan konvergensi, setelah itu dapat diintegrasikan dengan sistem industri bisa dilakukan melalui framework seperti ROS, dengan dukungan sensor fusion dan inference real-time untuk memastikan respons yang cepat dan akurat.

5. Assignment

Pada praktikum kali ini, kita melakukan percobaan membuat program kode digunakan untuk mendeteksi tangan (Hand Detection) secara real-time menggunakan kamera laptop/webcam dengan bantuan library MediaPipe dan OpenCV. Selain mendeteksi tangan, kode ini juga menandai setiap titik sendi tangan (joints), menggambar bounding box di sekitar tangan yang terdeteksi, memberi label kanan/kiri (Right/Left), serta menyimpan koordinat 3D setiap

sendi tangan ke file CSV bernama `hand_joints.csv`. Dengan demikian, hasil dari program ini bisa digunakan untuk pelatihan model pembelajaran mesin (Machine Learning) seperti Human Pose Estimation (HPE).

Setelah membuat kode program untuk deteksi tangan (Hand Detection) maka program akan dirunning lalu rogram akan membuka kamera, kemudian membaca setiap frame video secara berurutan. Setiap frame akan dibalik secara horizontal agar tampak seperti pantulan cermin, lalu dikonversi dari format warna BGR menjadi RGB sebelum diproses oleh model MediaPipe Hands. Jika tangan terdeteksi, program akan menggambar 21 titik sendi (joint) dan garis koneksi antar-sendinya pada gambar. Setiap titik juga diberi nomor urut (0–20) agar mudah diidentifikasi, dan di sekitar tangan ditampilkan kotak pembatas (bounding box) berwarna hijau lengkap dengan label “Right Hand” atau “Left Hand” sesuai hasil klasifikasi MediaPipe.


Selain menampilkan visualisasi secara langsung, kode ini juga menyimpan koordinat posisi setiap titik tangan dalam bentuk data 3 dimensi (x, y, z) ke dalam file CSV bernama `hand_joints.csv`. Data ini mencakup informasi seperti nomor frame, jenis tangan (kanan/kiri), ID sendi, serta nilai koordinatnya. Proses penyimpanan ini dilakukan secara otomatis untuk setiap frame yang berhasil diproses, sehingga file CSV akan berisi kumpulan data yang dapat digunakan lebih lanjut untuk pelatihan model Machine Learning atau Deep Reinforcement Learning (DRL) dalam konteks Human Pose Estimation (HPE) atau pengenalan gerakan tangan (gesture recognition). Untuk menjalankan kode ini, pengguna perlu menginstal dua library eksternal, yaitu `opencv-python` dan `mediapipe`.






Selain itu kita melakukan percobaan untuk membuat code program untuk simulasi membandingkan performa Deep Q-Network (DQN) sebagai metode Deep Reinforcement Learning (DRL) dengan Fuzzy Logic Controller (FLC) sebagai metode kontrol klasik. Sebelum itu kita harus mendownload library dari pip install `numpy matplotlib scikit-fuzzy`, maka dengan library tersebut, program dapat dijalankan, pada percobaan simulasi ini keduanya digunakan


untuk mengendalikan kecepatan kendaraan listrik agar mendekati target 50 km/jam. DQN menggunakan pendekatan pembelajaran berbasis nilai (Q-learning) dengan pembaruan Q-table secara iteratif melalui interaksi dengan lingkungan. Agen belajar menyesuaikan aksinya (mempercepat, mempertahankan, atau memperlambat) agar memperoleh reward maksimal, menunjukkan kemampuan beradaptasi dari waktu ke waktu tanpa perlu aturan yang ditentukan secara manual. Sebaliknya, Fuzzy Logic menggunakan aturan linguistik tetap seperti jika terlalu lambat maka percepat, jika terlalu cepat maka perlambat, yang membuatnya stabil tetapi tidak adaptif terhadap perubahan kondisi lingkungan. Hasil simulasi menunjukkan bahwa DQN mampu meningkatkan performa seiring bertambahnya episode karena proses pembelajaran, sementara Fuzzy Logic memberikan respon yang konsisten namun terbatas. Dengan demikian, DQN unggul dalam fleksibilitas dan kemampuan belajar dari pengalaman, sedangkan Fuzzy Logic lebih sederhana, stabil, dan mudah diimplementasikan.

6. Data dan Output Hasil Pengamatan

Pada praktikum didapatkan hasil pengujian untuk mendeteksi dan melacak posisi tubuh serta tangan manusia secara real-time melalui kamera web dan melakukan percobaan simulasi perbandingan performa antara algoritma Deep Q-Network (DQN) dengan metode kontrol klasik berbasis Fuzzy Logic sebagai berikut:

No	Variable	Hasil Pengamatan	Keterangan
1.	Deteksi Tangan Kiri		Berdasarkan gambar menunjukkan hasil deteksi tangan kiri secara otomatis dengan bounding box dan label name “Left Hand”

2.	Deteksi Tangan Kanan		Berdasarkan gambar menunjukkan hasil deteksi tangan kanan secara otomatis dengan bounding box dan label name “Right Hand”
3.	Deteksi Kedua Tangan		Berdasarkan gambar menunjukkan hasil deteksi kedua tangan secara otomatis dengan bounding box dan label name “Right Hand” dan juga label name “Left Hand”
4.	Deteksi Lebih dari 2 Tangan		Berdasarkan gambar menunjukkan hasil deteksi lebih dari kedua tangan secara otomatis dengan bounding box dan label name sesuai dengan deteksi tangan yang terdapat pada kamera
5.	Deteksi Selain Sendi Tangan		Berdasarkan gambar menunjukkan hasil deteksi selain dari sendi tangan maka tidak akan muncul bounding box dan label name
6.	Deteksi Badan		Program dapat mendeteksi sendi sendi pada seluruh tubuh secara real time. Selain itu, hanya manusia yang dapat terdeteksi, objek lain seperti noise yang ada diabaikan.

7.	Hasil Perbandingan Performa		grafik perbandingan rata-rata total reward antara metode DQN dan Fuzzy Logic selama proses pelatihan sebanyak 100 episode (ditampilkan dalam kelompok 10 episode per titik data). Sumbu horizontal (X) merepresentasikan jumlah episode pelatihan, sedangkan sumbu vertikal (Y) menunjukkan nilai Average Total Reward, yang mencerminkan seberapa baik sistem mampu mencapai target kecepatan yang diinginkan.
----	------------------------------------	--	--

7. Kesimpulan

Berdasarkan praktikum, analisis, dan hasil yang telah dilakukan, dapat disimpulkan bahwa:

- Library MediaPipe digunakan untuk mendeteksi landmark tangan dan menggambarinya pada setiap sendi tangan secara real-time
- Penggunaan metode DQN menunjukkan kemampuan adaptasi dan pembelajaran yang lebih baik dibandingkan menggunakan metode control klasik seperti Fuzzy Logic, karena dapat meningkatkan performa berdasarkan pengalaman. Fuzzy Logic tetap konsisten dan stabil, tetapi tidak mampu memperbaiki kinerjanya tanpa penyesuaian manual terhadap aturan kontrol

8. Saran

Dapat melakukan penambahan kode program untuk pengenalan gesture tangan menggunakan algoritma pembelajaran mesin yang lebih kompleks, seperti contoh tangan kanan diangkat untuk memberikan output seperti terdapat suara sirine dll, maka untuk hal itu dibutuhkan pembuatan klasifikasi berbagai gesture berdasarkan posisi landmark yang sesuai berdasarkan dengan datasets yang telah ada

9. Daftar Pustaka

- Achmad Ivan Taruna Jaya, Puspitaningayu, P., Adiwangsa, A. P., & Funabiki, N. (2024). Two-dimensional Human Pose Estimation using Key Points' Angular Detection for Basic Strength Training. *Journal of Intelligent System and Telecommunication*, 1(1), 105–119. <https://doi.org/10.26740/jistel.v1n1.p105-119>
- Dong, P., Chen, Z. M., Liao, X. W., & Yu, W. (2022). A deep reinforcement learning (DRL) based approach for well-testing interpretation to evaluate reservoir parameters. *Petroleum Science*, 19(1), 264–278. <https://doi.org/10.1016/j.petsci.2021.09.046>
- Khater, A. A., Fekry, M., El-Bardini, M., & El-Nagar, A. M. (2025). Deep reinforcement learning-based adaptive fuzzy control for electro-hydraulic servo system. *Neural Computing and Applications*, 0123456789. <https://doi.org/10.1007/s00521-024-10741-x>
- Qin, S., Zhang, X., Wang, J., Guo, X., Qi, L., Cao, J., & Liu, Y. (2024). An Improved Q-Learning Algorithm for Optimizing Sustainable Remanufacturing Systems. *Sustainability (Switzerland)*, 16(10), 1–18. <https://doi.org/10.3390/su16104180>
- Samkari, E., Arif, M., Alghamdi, M., & Al Ghamdi, M. A. (2023). Human Pose Estimation Using Deep Learning: A Systematic Literature Review. *Machine Learning and Knowledge Extraction*, 5(4), 1612–1659. <https://doi.org/10.3390/make5040081>
- Yamagata, T., Khalil, A., & Santos-Rodríguez, R. (2023). Q-learning Decision

Transformer: Leveraging Dynamic Programming for Conditional Sequence Modelling in Offline RL. *Proceedings of Machine Learning Research*, 202, 38989–39007.